

DeepSeek-R1

DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning

Introduction

LLM의 reasoning 성능을 높이는 대표적인 방법은 사람이 만든 Chain-of-Thought(CoT) reasoning data를 이용해 SFT하는 것이었음.

하지만 고품질 reasoning trajectory를 사람이 직접 만드는 것은 비용이 많이 들고 scale-up하기 어려움.

DeepSeek-R1 논문의 핵심 질문은:

사람이 reasoning 방법을 직접 알려주지 않고, 정답에 대한 reward만 주어도 LLM이 스스로 reasoning behavior를 학습할 수 있는가?

임.

Main Goal

Human-labeled reasoning trajectory에 강하게 의존하지 않고,

Reinforcement Learning을 통해 LLM의 reasoning capability를 직접 학습시키는 것.

논문에서는 크게

1. DeepSeek-R1-Zero
2. DeepSeek-R1

두 모델을 설명함.

DeepSeek-R1-Zero

DeepSeek-R1-Zero는 가장 중요한 실험적 아이디어.

SFT를 reasoning 학습 이전에 하지 않고, DeepSeek-V3-Base에 바로 RL을 적용함.

즉,

DeepSeek-V3-Base
↓
GRPO
↓
DeepSeek-R1-Zero

사람이 만든 CoT를 먼저 imitation하게 하지 않고,
문제를 풀고 정답을 맞혔는지를 reward로 주면서 reasoning behavior 자체가
emergence하는지를 확인.

Method

Group Relative Policy Optimization (GRPO)

RL algorithm으로 **GRPO**를 사용.

일반적인 PPO에서는 value model(Critic)을 별도로 학습하는 경우가 있는데, GRPO는 같은 question에서 여러 response를 sample하고 **group 내부의 상대적인 reward**를 이용해 advantage를 계산함.

Question q 하나에 대해 G 개의 output을 생성.

$$\{o_1, o_2, \dots, o_G\}$$

각 output의 reward가

$$r_1, r_2, \dots, r_G$$

라고 하면 advantage를 대략

$$A_i = \frac{r_i - \text{mean}(r_1, \dots, r_G)}{\text{std}(r_1, \dots, r_G)}$$

로 계산.

- q : input question
- o_i : model이 생성한 i 번째 response
- r_i : 해당 response가 받은 reward
- A_i : group 평균과 비교한 상대적인 advantage

- π_θ : 현재 policy model
- $\pi_{\theta_{old}}$: sampling에 사용된 이전 policy
- π_{ref} : reference model

즉 같은 문제에 여러 답을 생성한 뒤,

평균보다 잘한 response의 probability는 올리고, 못한 response는 낮추는 방향으로 학습한다고 보면 됨.

Reward Design

DeepSeek-R1-Zero에서는 reasoning content를 사람이 직접 scoring하는 복잡한 reward model보다 **rule-based reward**를 사용.

크게 두 개.

Accuracy Reward

최종 answer가 맞았는지 평가.

수학 문제처럼 정답이 명확한 경우 정답을 직접 비교할 수 있고,

code 문제는 test case나 compiler를 사용해서 correctness를 평가할 수 있음.

Format Reward

Reasoning과 final answer를 정해진 format으로 출력하는지 평가.

논문에서는 reasoning을 `<think>...</think>`, final answer를 `<answer>...</answer>` 형태로 구분하도록 함.

전체 reward:

$$Reward_{rule} = Reward_{acc} + Reward_{format}$$

핵심은 “어떻게 reasoning해야 하는지”에 대한 정답 trajectory를 제공하지 않았다는 것.

정답을 맞히면 reward를 주고 model이 reasoning strategy를 스스로 찾도록 함.

Emergence of Reasoning

RL 학습이 진행되면서 R1-Zero의 output length가 길어지고 reasoning behavior가 발현함.

Model이 명시적으로 학습받지 않았는데도

- self-reflection
- verification
- alternative solution exploration
- longer Chain-of-Thought

같은 behavior를 보이기 시작함.

논문에서는 이를 대표적으로 **"Aha Moment"**라고 설명.

문제를 풀다가 스스로 앞선 reasoning을 다시 검토하고 다른 방법을 시도하는 behavior가 자연스럽게 나타남.

AIME 2024 pass@1도 RL 과정에서 크게 증가.

즉 핵심 실험 결과는:

Reasoning trajectory를 직접 SFT하지 않아도 correctness reward를 이용한 RL만으로 reasoning capability가 상당 부분 emergence할 수 있음.

Limitations of R1-Zero

R1-Zero가 reasoning은 강해졌지만 문제가 존재.

- readability가 좋지 않음.
- English와 Chinese 등이 섞이는 language mixing 발생.
- reasoning task 외 일반적인 writing, open-domain QA 등의 capability가 충분하지 않음.

즉 **Reasoning 성능만 높다고 실제 assistant model로 바로 사용하기 좋은 것은 아니었음.**

이를 보완한 것이 DeepSeek-R1.

DeepSeek-R1

DeepSeek-R1은 Pure RL 하나만 사용하는 R1-Zero와 달리 **multi-stage training pipeline**을 사용함.

전체 흐름을 핵심만 보면:

```
DeepSeek-V3-Base
  ↓
Cold-Start Data
  ↓
First RL Stage
  ↓
Rejection Sampling + SFT
  ↓
Second RL Stage
  ↓
DeepSeek-R1
```

Cold Start

처음부터 pure RL만 사용했을 때 발생한 readability와 language mixing 문제를 줄이기 위해,

소량의 high-quality reasoning data로 model을 먼저 초기화.

즉 R1-Zero에서 확인한 pure RL의 가능성을 유지하면서 실제 사용 가능한 reasoning format을 유도.

First RL Stage

GRPO 기반 RL을 이용하여 reasoning capability를 향상.

R1-Zero와 유사하게 math, code, logical reasoning task에서 rule-based reward를 사용.

추가적으로 language consistency를 고려하여 readability를 개선.

Rejection Sampling + SFT

RL로 생성된 reasoning output 중 좋은 sample을 선별하고,

reasoning data와 non-reasoning data를 함께 사용하여 SFT.

Model이 reasoning만 잘하는 것이 아니라 writing, QA 등 일반 capability도 유지하도록 함.

Second RL Stage

마지막으로 reasoning capability뿐만 아니라

- helpfulness
- harmlessness

등 human preference까지 고려한 추가 RL을 수행.

즉 R1은 단순한 "Pure RL Model"이 아니라,

Cold Start → RL → SFT → RL의 multi-stage post-training pipeline으로 보는 것이 정확함.

Distillation

DeepSeek-R1에서 학습된 reasoning behavior를 smaller model로 전달하는 실험도 수행.

Large R1 model이 생성한 reasoning data를 이용해 Qwen/Llama 기반 smaller dense model을 fine-tuning함.

핵심은 큰 모델에서 emergence한 reasoning pattern을 작은 모델이 학습할 수 있다는 것.

논문에서는 여러 distilled model을 공개함.

즉,

```
DeepSeek-R1
  ↓
Reasoning Data
  ↓
Smaller Base Model
  ↓
Distilled Reasoning Model
```

형태.

Experiments

DeepSeek-R1과 R1-Zero는 대표적으로

- Mathematics
- Coding
- STEM Reasoning
- General Benchmark

등에서 평가.

R1-Zero 자체도 RL만으로 AIME와 coding task에서 reasoning 성능이 크게 향상됨.

DeepSeek-R1은 여기에 multi-stage training을 추가하여 reasoning뿐 아니라 instruction following과 general capability까지 개선.

논문의 핵심 실험적 메시지는 성능 숫자 하나보다 다음 두 가지임.

1. **Pure RL만으로도 reasoning behavior가 emergence할 수 있음.**
2. **실제 사용 가능한 reasoning model을 만들기 위해서는 cold-start/SFT/general preference alignment를 결합한 multi-stage training이 효과적임.**

R1-Zero vs R1

Model	핵심
DeepSeek-R1-Zero	SFT 없이 Base Model에 바로 RL. Reasoning emergence 확인
DeepSeek-R1	Cold Start + RL + SFT + RL. Readability와 general capability까지 보완

R1-Zero는 “RL만으로 reasoning이 가능한가?”를 보여주는 실험적 모델.

R1은 그 결과를 실제 high-performance reasoning model로 발전시킨 모델.

핵심 정리

DeepSeek-R1 논문의 가장 중요한 포인트는 단순히 새로운 LLM architecture를 만든 것이 아님.

Post-Training 방법론, 특히 Reinforcement Learning을 이용해 reasoning을 어떻게 끌어낼 것인지가 핵심.

R1-Zero:

```
Base Model
  ↓
GRP0 + Rule-based Reward
  ↓
Reasoning Emergence
```

R1:

```
Base Model
↓
Cold Start
↓
Reasoning RL
↓
Rejection Sampling + SFT
↓
Preference / General RL
↓
DeepSeek-R1
```

결국,

좋은 reasoning trajectory를 전부 사람이 직접 작성하지 않더라도, verifiable reward를 이용한 RL을 통해 LLM이 self-reflection, verification 같은 reasoning behavior를 스스로 발전시킬 수 있음을 보여준 논문.

Paper

- DeepSeek-AI et al., *DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning*
- <https://arxiv.org/abs/2501.12948>